

DEEPBRUCE-AI

Relatorio tecnico de evolucao do projeto

Data: 22 de setembro de 2026

1. VISAO GERAL

O projeto foi evoluído mantendo a proposta original: um assistente local com personalidade de mago, API Flask com streaming SSE, Ollama, RAG baseado em Wikipedia e interface React visualmente cosmica.

2. FRONTEND REACT

Identidade visual:

- template.png passou a ser usado como fundo do hero.
- Logotipo.png passou a ser usado no topo, rodape e V2 Vision.
- main_icone.png ficou na apresentacao Meet Bruce.
- chat_avatar.png foi criado para o avatar pequeno das respostas.
- ferramentas_icones.png foi inserido na secao de arquitetura.
- favicon.png foi registrado no index.html.

Experiencia do chat:

- O avatar do DeepBruce aparece ao lado das mensagens do assistente.
- O botao New chat recebeu estilo proprio.
- Os controles superiores deixaram de usar a aparencia nativa do navegador.
- O quadro do chat recebeu altura fixa e rolagem interna.
- O quadro nao cresce conforme a resposta aumenta.
- O scroll acompanha a mensagem mais recente.

Temas e ambiente:

- O light mode recebeu cores, fundos, cards e inputs proprios.
- O avatar nao sofre mais efeito de mistura que o deixava esbranqui?ado.
- O logo real passou a ser usado no lugar do logo textual.
- Duas camadas de estrelas foram criadas com CSS puro.
- As estrelas usam gradientes radiais e movimento sutil.
- A animacao respeita prefers-reduced-motion.
- A intensidade das estrelas e reduzida no light mode.

3. BACKEND FLASK

Fluxo RAG:

- Corrigido o uso de resolution antes de sua inicializacao.
- Pesquisa geral chama o RAG diretamente.
- Entidade resolvida usa resolved_title.
- O idioma detectado continua sendo preservado.

Respostas mais objetivas:

- page_limit reduzido de 3 para 2.
- top_k reduzido de 5 para 3.
- Contexto reduzido de 10000 para 5000 caracteres.
- num_predict do Ollama reduzido de 768 para 384 tokens.
- O prompt orienta resumos introdutorios de 2 a 4 paragrafos curtos.
- O modelo nao deve reproduzir uma biografia inteira.

4. PERSONALIDADE DO DEEPBRUCE

Foi criada uma personalidade compartilhada para chat comum e RAG.

O DeepBruce deve ser:

- Enigmático, misterioso, sereno e perspicaz.
- Acolhedor, elegante e levemente místico.
- Capaz de usar pequenas metáforas sobre estrelas, mapas e tomos.
- Preciso e honesto ao apresentar fatos.
- Sutil, sem transformar toda resposta em teatro.
- Direto antes de aprofundar a parte narrativa.

Objetivo da experiência: o usuário deve sentir que está conversando com um mago de verdade, sem perder clareza, utilidade ou precisão.

5. ENTITY RESOLUTION E AMBIGUIDADE

O fluxo foi ajustado para não adivinhar entidades incompletas.

Exemplo:

Quem é o Justin?

- > Você se refere a qual Justin?
- > Justin Bieber
- > Justin Timberlake
- > Justin Trudeau

Perguntas com nome completo, como Quem foi Alan Turing?, continuam podendo ser resolvidas automaticamente.

Erros de digitação como Justem tentam usar sugestões da Wikipedia antes da decisão final. Se houver candidatos, o sistema pede esclarecimento. Nomes curtos sem candidatos também pedem nome completo, em vez de cair diretamente em `entity_not_found`.

6. API E CONFIGURAÇÃO

- `MAX_MESSAGE_LENGTH` foi adicionado com padrão de 4000 caracteres.
- O limite é aplicado em `/api/message` e `/api/rag/chat`.
- Mensagens acima do limite retornam HTTP 400.
- Autenticação obrigatória não foi adicionada nesta versão.
- Redis e persistência compartilhada ficaram reservados para a v2.

O ambiente local usa `OLLAMA_HOST=http://127.0.0.1:11434`.

O Docker Compose usa `http://ollama:11434` dentro da rede dos containers.

7. DOCKER E OPERAÇÃO

- `requirements-rag.txt` inclui `requirements.txt` via `-r`.
- `nlTK` foi adicionado e a duplicação foi removida.
- O `Dockerfile` instala o conjunto completo do RAG.
- `Gunicorn` foi reduzido para um worker na v1.5.
- Um worker preserva a consistência do `ConversationManager` em memória.

8. TESTES E CI

Foram corrigidos testes de streaming do Ollama e do orchestrator.

Foram adicionados testes para:

- Pesquisa geral sem Entity Resolver.

- Nome curto ambiguo com varios candidatos.
- Nome curto ambiguo com um candidato.
- Nome curto sem resultado.
- Limite de tamanho de mensagens.
- Limite num_predict do Ollama.

A CI agora executa:

- Testes Python com pytest.
- npm ci.
- npm run lint.
- npm run build.

9. DOCUMENTACAO

O README foi completado com setup Python, .env, Ollama, frontend React, testes, Docker, arquitetura v1.5 e o aviso de que V2 Vision e roadmap/concept.

10. LIMITES ATUAIS E PROXIMOS PASSOS

- O Ollama precisa estar ativo e acessivel na porta 11434.
- A primeira resposta pode demorar enquanto o modelo carrega.
- O ConversationManager ainda e mantido em memoria.
- Redis ou banco compartilhado ficam para a v2.
- A CI e o local sao os caminhos recomendados para validacao completa.

CONCLUSAO

O DeepBruce-AI agora possui uma experiencia visual integrada com as artes do projeto, chat estavel, identidade de mago, RAG mais conciso, resolucao de entidades mais segura, limites de entrada, Docker alinhado e CI cobrindo backend e frontend, sem abandonar a ideia original da v1.5.